

Fiches pédagogiques - Biostatistique

Fiche 1 - Analyse CSV

Objectif pédagogique

Explorer et nettoyer un fichier de terrain réel. Identifier les problèmes de qualité de données avant toute analyse.

Concept clé

Un fichier de terrain brut contient presque toujours des valeurs manquantes, des unités mélangées ou des colonnes mal typées. L'exploration préalable est une étape incontournable.

Manipulations guidées

1. Importer le fichier CSV (séparateur auto-déecté)
2. Lire le résumé automatique : lignes, colonnes, valeurs manquantes
3. Sélectionner une colonne numérique => observer histogramme + boîte à moustaches
4. Choisir deux variables => tracer le nuage de points et lire R^2
5. Comparer deux groupes avec le test de Welch => lire p-value
6. Exporter CSV nettoyé + PDF résumé

Questions d'interprétation

- Q1. La moyenne est supérieure à la médiane pour 'comptage'. Qu'est-ce que cela indique ?
- Q2. CV = 85 %. Que dit cela sur l'hétérogénéité inter-sites ?
- Q3. p-value = 0.23 (Welch). Peut-on conclure que les habitats sont identiques ?
- Q4. $r = 0.91$ entre deux colonnes. Est-ce une preuve de causalité ?

Erreurs fréquentes

- X Mélanger des unités dans une même colonne (g et kg)
- X Interpréter corrélation comme causalité
- X Ignorer les valeurs manquantes avant de calculer une moyenne

Fiche 2 - Statistiques descriptives

Objectif pédagogique

Résumer une distribution de comptages ou de mesures morphologiques. Choisir le bon indicateur selon la forme de la distribution.

Concept clé

La moyenne seule ne suffit pas. Une distribution asymétrique (fréquente en ornithologie) nécessite la médiane et les quartiles. L'écart-type mesure la dispersion, pas la forme.

Manipulations guidées

1. Régler nombre de sites, abondance moyenne, agrégation spatiale
2. Comparer moyenne vs médiane selon le niveau d'agrégation
3. Augmenter le nombre de sites => observer la stabilisation des indicateurs

Questions d'interprétation

- Q1. Avec forte agrégation : moyenne = 18, médiane = 8. Quelle valeur représente 70% des sites ?
- Q2. L'écart-type est plus grand que la moyenne. Qu'implique-t-on pour un test de normalité ?
- Q3. Pourquoi les ornithologues utilisent-ils des modèles de comptage (Poisson) ?

Fiche 3 - Corrélation et régression

Objectif pédagogique

Quantifier la relation linéaire entre deux variables biologiques. Distinguer la force d'association (r , R^2) de la signification statistique (p-value).

Formules

r de Pearson = $\text{Cov}(X,Y) / (\sigma_X \times \sigma_Y)$ dans $[-1 ; 1]$

R^2 = r^2 (proportion de variance expliquée)

$Y_{\text{prédit}}$ = $a + b \times X$

Questions d'interprétation

- Q1. $n = 200$, $r = 0.15$, $p = 0.02$. La relation est-elle biologiquement importante ?
- Q2. Pente = 2.3 g/mm. Que signifie ce chiffre pour masse ~ longueur d'aile ?
- Q3. $R^2 = 0.62$. Quelle proportion de la variance n'est pas expliquée ?

Erreurs fréquentes

- X Confondre r (corrélation) et R^2 (proportion de variance)
- X P-value faible $\neq$ relation forte | R^2 élevé $\neq$ causalité
- X Interpréter l'intercept quand $X = 0$ est hors domaine biologique

Fiche 4 - Tests statistiques

Objectif pédagogique

Comparer des groupes biologiques (habitats, années, traitements). Choisir le bon test selon la structure des données.

Test	Quand l'utiliser
t-test de Welch	2 groupes, variable continue, variances potentiellement inégales
ANOVA	3 groupes ou plus, variable continue
Mann-Whitney	Alternative non-paramétrique au t-test
Khi-deux	Comparer des fréquences ou proportions

Questions d'interprétation

- Q1. $p = 0.04$ avec $n = 10$. Que faire avant de conclure ?
- Q2. Deux habitats : moyennes 12 et 18, $p = 0.001$. La différence est-elle biologiquement importante ?
- Q3. Interpréter $p > 0.05$ comme 'les groupes sont identiques' - est-ce correct ?

Concept clé

Les comptages (0, 1, 2, ...) ne suivent pas une loi normale. Le GLM Poisson est la base ; le binomial négatif gère la surdispersion (variance > moyenne) fréquente en ornithologie.

Sélection du modèle

- 1. Ajuster GLM Poisson => observer ratio Déviance/ddl
- 2. Ratio >> 1 => surdispersion => basculer sur Binomial négatif
- 3. Comparer les AIC (plus bas = mieux)

```
exp(beta)  =  effet multiplicatif d'une covariable sur le comptage moyen
exp(0.85)  =  2.34  =>  2.34 fois plus d'individus dans le groupe de référence
```

Fiche 6 - Modèles mixtes (LMM)

Concept clé

Quand plusieurs mesures viennent du même site ou individu, elles ne sont pas indépendantes (pseudo-réplication). Un modèle mixte ajoute des effets aléatoires pour capturer cette structure.

Terme	Définition
Effet fixe	Variable d'intérêt (habitat, traitement) - estimée en moyenne
Effet aléatoire	Variable de groupement (site, individu) - variabilité contrôlée
ICC	Corrélation intra-classe : proportion de variance due au groupement

- Q1. ICC = 0.05 : le modèle mixte est-il nécessaire ?
- Q2. Données : 10 obs/oiseau bagué sur 5 individus => effet aléatoire recommandé ?

Fiche 7 - Domaines vitaux : MCP et KDE

Méthode	Description	Avantage	Limite principale
MCP	Polygone convexe minimum contenant tous les points	Simple, universel	Sensible aux points extrêmes
KDE	Distribution de probabilité de présence (noyau gaussien)	Probabiliste, isopleths ajustables	Paramètre h à choisir, plus de points requis

Paramètres clés

- MCP 95% : exclure 5% des points aberrants => surface réduite
- KDE 50% : zone noyau d'utilisation intensive
- KDE 95% : domaine vital complet
- Bande passante h : fort lissage => contours lisses ; faible => sur-ajustement

Questions d'interprétation

- Q1. MCP 100% = 1850 ha, MCP 95% = 620 ha. Que révèle cet écart ?
- Q2. L'isoplèthe KDE 50% représente quoi biologiquement ?
- Q3. Pourquoi ne pas comparer des MCP calculés avec des n différents ?

Récapitulatif - Choisir la bonne méthode

Situation	Module recommandé
Résumer des données de terrain	Analyse CSV + Statistiques descriptives
Deux variables continues	Corrélation & régression
Deux groupes à comparer	Tests statistiques (t-test ou Mann-Whitney)
Trois groupes ou plus	Tests statistiques (ANOVA)
Modéliser des comptages	GLM Comptage
Données groupées par site/individu	Modèles mixtes
Positions GPS => domaine vital géométrique	Domaine vital MCP
Positions GPS => domaine vital probabiliste	Domaine vital KDE