

ORNI-LAB

Laboratoire Interactif de Modélisation Ornithologique



Auteur	Abdoulaye Diop — Bioinformaticien · Biomathématicien
Spécialisation	Analyse & modélisation des systèmes biologiques · Écologie quantitative
Contact	dioplayes@gmail.com · +221 77 113 07 48
Version	2.0 — Mai 2026
Modules	18 modules interactifs répartis en 2 sections
Sections	Biostatistique (8 modules) · Dynamique des populations (10 modules)
Audience	Licence 3 · Master 1 & 2 · Doctorat · Formation professionnelle
Technologies	Python 3.11 · Streamlit · SciPy · Statsmodels · Plotly · ReportLab
Date de génération	15 May 2026

Table des matières

1. Introduction et philosophie pédagogique

2. Architecture technique

3. Installation et configuration

4. Guide d'utilisation détaillé

4.1 Démarrage et navigation

4.2 Chargement de données CSV

4.3 Mode Étudiant / Enseignant

4.4 Exports PDF et CSV

5. Section Biostatistique — 8 modules

5.1 Statistiques descriptives

5.2 Analyse CSV guidée

5.3 Corrélation et régression

5.4 Tests statistiques

5.5 GLM pour données de comptage

5.6 Modèle mixte — LMM

5.7 Domaine vital — MCP

5.8 Domaine vital — KDE

6. Section Dynamique des populations — 10 modules

6.1 Richesse spécifique et diversité

6.2 Croissance exponentielle et logistique

6.3 Matrices de Leslie

6.4 Capture-Marquage-Recapture

6.5 Modèles d'occupation

6.6 Distance sampling

6.7 Lotka-Volterra

6.8 Séries temporelles de population

6.9 PVA et conservation

6.10 Scénarios de gestion

7. Annexes techniques

7.1 Dépendances Python et versions

7.2 Sécurité et robustesse

7.3 Erreurs fréquentes et solutions

8. Glossaire des termes statistiques

9. Références bibliographiques

1. Introduction et philosophie pédagogique

ORNI-LAB est un laboratoire interactif de modélisation ornithologique développé pour l'enseignement universitaire en écologie des populations et en biologie de la conservation. Conçu comme un outil pédagogique à part entière, il offre une interface web intuitive permettant aux étudiants et aux enseignants d'explorer, de visualiser et d'analyser des données ornithologiques sans prérequis en programmation.

L'application repose sur cinq principes pédagogiques fondamentaux :

- **Dualité simulation / terrain** — chaque module fonctionne en mode simulation (paramètres ajustables, données générées) ET en mode données réelles (import CSV). Cette dualité permet de passer de l'abstraction mathématique à la pratique de terrain.
- **Progression de l'interprétation** — les résultats sont accompagnés d'interprétations automatiques en langage naturel, évitant la surcharge cognitive des étudiants débutants.
- **Mode Enseignant intégré** — formules mathématiques LaTeX, notes pédagogiques avancées et erreurs fréquentes apparaissent en mode Enseignant, enrichissant le cours magistral sans alourdir l'interface étudiant.
- **Reproductibilité** — chaque simulation utilise une graine aléatoire fixable, garantissant des résultats identiques entre sessions de TP.
- **Export immédiat** — résumés PDF et données CSV exportables depuis chaque module pour prolonger l'analyse dans R, Python ou Excel.

ORNI-LAB couvre deux grandes disciplines de l'ornithologie quantitative : la biostatistique (tests d'hypothèses, régression, modèles mixtes, domaine vital) et la dynamique des populations (croissance, structures d'âge, CMR, occupation, distance sampling, PVA). L'ensemble constitue un cursus complet du L3 au M2, adaptable à des publics de biologistes, d'écologues ou de gestionnaires d'espaces naturels.

2. Architecture technique

L'application est construite en Python 3.11 avec le framework Streamlit. L'architecture suit un patron MVC simplifié où chaque module est un renderer indépendant recevant un contexte partagé.

Couche	Rôle	Fichiers principaux
Interface	Navigation, session state, mise en page	app/main.py, app/config.py
Modules	18 simulateurs/analyseurs spécialisés	modules/*.py
UI partagée	Composants visuels réutilisables	utils/ui.py
Export	Génération PDF (ReportLab) et CSV	core/export.py
Simulations	Moteur PVA stochastique	simulations/pva_engine.py

Données	Valeurs par défaut et datasets d'exemple	data/examples.py
Tests	Suite de 28 tests unitaires (pytest)	tests/test_models.py

Pattern render(context)

Chaque module expose une unique fonction `render(context: dict)`. Le dictionnaire `context` contient les données partagées par tous les modules :

- `context['data']` — DataFrame pandas chargé depuis le CSV sidebar (None si simulation)
- `context['numeric_columns']` — liste des colonnes numériques détectées
- `context['categorical_columns']` — liste des colonnes catégorielles
- `context['teacher_mode']` — booléen activant les notes pédagogiques

Gestion d'erreurs

Depuis la version 2.0, `app/main.py` encapsule chaque appel `render()` dans un bloc `try/except`. Toute exception non gérée dans un module s'affiche comme un message d'erreur avec traceback complet dans un `expand`, sans planter l'application globale.

3. Installation et configuration

Prérequis système

- Python 3.10 ou supérieur (recommandé : 3.11)
- pip ou conda (gestionnaire de paquets)
- Système d'exploitation : Windows 10/11, macOS 12+, ou Linux Ubuntu 20.04+
- RAM : 4 Go minimum, 8 Go recommandés pour les simulations PVA intensives
- Espace disque : ~500 Mo pour l'environnement virtuel complet

Installation des dépendances

Depuis le répertoire racine du projet, exécuter :

```
pip install streamlit>=1.40
pip install numpy scipy pandas statsmodels
pip install plotly reportlab
```

Lancement de l'application

Trois méthodes de lancement sont disponibles :

- **Raccourci bureau** — double-clic sur `ORNI-LAB.lnk` (créé par `installer_raccourci.ps1`)
- **Batch Windows** — double-clic sur `ORNI-LAB.bat` (libère le port 8501, lance Streamlit, ouvre le navigateur automatiquement)
- **Lancement silencieux** — double-clic sur `ORNI-LAB_silencieux.vbs` (sans fenêtre CMD visible, idéal pour une utilisation en salle TP)

• **Ligne de commande** — `python -m streamlit run app/main.py --server.port 8501`

■ L'application est accessible à l'adresse `http://localhost:8501` dans tout navigateur web moderne. Aucune connexion internet n'est requise après installation.

4. Guide d'utilisation détaillé

4.1 Démarrage et navigation

Au démarrage, la page d'accueil présente deux cartes de section cliquables : Biostatistique (bleu) et Dynamique des populations (vert). Un clic sur une carte ouvre la section et affiche la liste des modules dans la sidebar gauche. Le bouton ← Accueil permet de revenir à tout moment à la page principale.

4.2 Chargement de données CSV

La zone de chargement CSV se trouve en haut de la sidebar. L'application supporte les encodages UTF-8, UTF-8 BOM, Latin-1, CP1252 et UTF-16. Le séparateur (virgule, point-virgule, tabulation) est détecté automatiquement via `csv.Sniffer`. Une fois chargé, le fichier est utilisé par tous les modules simultanément.

- Les colonnes avec $\geq 70\%$ de valeurs numériques sont classées comme numériques
- Les virgules décimales sont converties automatiquement en points
- Les valeurs manquantes (NA, N/A, null, -, ?) sont normalisées en NaN
- Chaque module propose un bouton de téléchargement du template CSV adapté

4.3 Mode Étudiant / Enseignant

Le mode s'active depuis la sidebar avec le bouton bascule. En mode Étudiant (défaut) : résultats, graphiques et interprétations automatiques. En mode Enseignant : s'ajoutent les formules mathématiques, les notes pédagogiques sur les choix méthodologiques, et les pièges classiques des étudiants mis en évidence.

4.4 Exports PDF et CSV

Chaque module propose en bas de page un ou plusieurs boutons d'export. Le PDF contient un résumé des résultats avec interprétation, généré par ReportLab (`core/export.py`). Le CSV exporte les données utilisées (simulées ou importées) pour une analyse complémentaire.

Section 5 — Biostatistique (8 modules)

BIOSTATISTIQUE

E

5.1. Statistiques descriptives

Description

Module d'exploration initiale d'un jeu de données ornithologique. Il calcule les statistiques de position et de dispersion pour chaque variable numérique, trace des histogrammes de distribution, des boîtes à moustaches comparatives, et une matrice de corrélation visuelle (heatmap). Ce module est systématiquement le point d'entrée avant toute analyse inférentielle.

Fondements méthodologiques

Pour chaque variable numérique, le module calcule : n , moyenne, médiane, écart-type, variance, minimum, maximum, $Q1$, $Q3$, $IQR = Q3 - Q1$. La matrice de corrélation de Pearson est calculée sur toutes les paires de variables numériques (`pandas.DataFrame.corr`). Les boîtes à moustaches affichent la médiane, les quartiles et les valeurs aberrantes au-delà de $Q1 - 1.5 \cdot IQR$ et $Q3 + 1.5 \cdot IQR$.

```
Moyenne :  $\bar{x} = (1/n) * \sum(x_i)$ 
Variance :  $s^2 = (1/(n-1)) * \sum((x_i - \bar{x})^2)$ 
IQR :  $IQR = Q3 - Q1$ 
Outliers :  $x < Q1 - 1.5 \cdot IQR$  OU  $x > Q3 + 1.5 \cdot IQR$ 
Pearson :  $r = \text{cov}(x,y) / (s_x * s_y)$ 
```

Algorithme pas à pas

- Chargement et typage automatique des colonnes du CSV
- Calcul des statistiques descriptives (`pandas.describe` + moments supplémentaires)
- Détection des valeurs aberrantes par la règle IQR
- Construction de la matrice de corrélation et affichage en heatmap
- Génération des histogrammes et boîtes à moustaches par groupe si variable catégorielle présente

Application ornithologique

Utilisé pour explorer des jeux de données de morphométrie (envergure, masse, longueur du tarse), de comptages sur points d'écoute, ou de données de baguage. Permet de vérifier si les distributions sont approximativement normales avant d'appliquer des tests paramétriques, et d'identifier les valeurs aberrantes liées à des erreurs de saisie ou à des individus atypiques (juvéniles, hybrides).

Paramètres d'entrée

Sorties et résultats

- Fichier CSV avec colonnes numériques et/ou catégorielles
- Sélection de la variable à visualiser
- Variable de groupement optionnelle
- Tableau : n, moyenne, médiane, SD, min, Q1, Q3, max, IQR
- Histogramme de distribution avec courbe de densité
- Boîtes à moustaches (par groupe si applicable)
- Heatmap de la matrice de corrélation de Pearson
- Liste des valeurs aberrantes détectées

Comment interpréter les résultats

■ Une distribution normale apparaît comme une cloche symétrique sur l'histogramme. Une médiane très différente de la moyenne indique une asymétrie. Un r de Pearson > 0.7 indique une forte corrélation linéaire ; $r > 0.9$ suggère quasi-colinéarité. Les points hors moustaches sont des candidats à vérification (erreur de saisie ou biologie réelle).

Erreurs fréquentes à éviter

■ Confondre corrélation et causalité : deux variables corrélées (ex. masse et envergure) ne signifient pas que l'une cause l'autre — une troisième variable (âge, sexe) peut expliquer les deux.

■ Utiliser la moyenne sur une distribution fortement asymétrique (ex. comptages) : préférer la médiane comme indicateur de position centrale.

■ Ignorer les valeurs aberrantes avant l'analyse : elles peuvent inflater l'écart-type et masquer la vraie variabilité biologique.

Importance en écologie et conservation

L'analyse exploratoire des données (AED) est la fondation de tout travail statistique rigoureux. Elle prévient les erreurs d'interprétation dues à des données non vérifiées, guide le choix des méthodes ultérieures, et permet de détecter les problèmes de qualité avant qu'ils ne biaisent les conclusions biologiques.

Référence clé

Tukey, J.W. (1977). *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.

BIOSTATISTIQUE

5.2. Analyse CSV guidée

Description

Module d'exploration automatisée et approfondie d'un fichier CSV de terrain. Il détecte l'encodage et le séparateur, nettoie les données (valeurs manquantes, virgules décimales, alias nuls), propose une analyse univariée complète par variable (16 statistiques, test de normalité), une analyse bivariée

multi-types (numérique-numérique, numérique-catégorielle, catégorielle-catégorielle), une matrice de corrélation interactive, et un export structuré en 6 onglets.

Fondements méthodologiques

Détection d'encodage : essai successif UTF-8, UTF-8 BOM, Latin-1, CP1252, UTF-16. Séparateur : csv.Sniffer sur les 4096 premiers octets. Nettoyage : normalisation des valeurs null (NA, N/A, null, -, ?, --), correction décimale virgule->point, détection colonnes dates. Profil univarié : moyenne, médiane, mode, SD, skewness, kurtosis, IQR, N outliers IQR, N outliers Z>3, Shapiro-Wilk ($n \leq 5000$) ou KS ($n > 5000$). Bivarié num-num : Pearson + Spearman + OLS. Bivarié num-cat 2 gr : Welch + Mann-Whitney. k gr : ANOVA + Kruskal-Wallis + η^2 . Bivarié cat-cat : chi-carré + V de Cramér.

```
Skewness : g1 = (1/n) * sum((x_i - x_bar)^3) / s^3
Kurtosis : g2 = (1/n) * sum((x_i - x_bar)^4) / s^4 - 3
V de Cramér: V = sqrt(chi^2 / (n * (min(r,c) - 1)))
Spearman : r_s = Pearson calculé sur les rangs de x et y
eta^2 : eta^2 = SS_between / SS_total
```

Algorithme pas à pas

- Tentative de lecture avec 5 encodages x séparateur sniffé, fallback tous séparateurs
- Nettoyage profond : NULL aliases, virgule->point, détection types, dates
- Classification des colonnes : numérique, catégorielle, date, texte
- Calcul du profil complet pour chaque colonne numérique (16 statistiques)
- Analyse bivariée adaptée au type des deux colonnes sélectionnées
- Construction de la matrice de corrélation (Pearson ou Spearman au choix)
- Affichage en 6 onglets : Aperçu, Qualité, Univarié, Relations, Corrélations, Export

Application ornithologique

Point d'entrée universel pour tout fichier de terrain : données STOC, SHOC, BBS, LPO, baguage, transects, grilles EPS. Permet à un étudiant de charger ses propres données de TP sans connaissance préalable du format et d'obtenir une analyse statistique complète avec test d'hypothèse adapté au type de données.

Paramètres d'entrée

- Fichier CSV (encodage et séparateur auto-détectés)
- Sélection des colonnes pour l'analyse bivariée
- Choix Pearson / Spearman pour la matrice de corrélation

Sorties et résultats

- Onglet Aperçu : premières lignes, types, dimensions du jeu de données
- Onglet Qualité : % valeurs manquantes, doublons, colonnes constantes
- Onglet Univarié : 16 statistiques + test normalité + histogramme + boxplot
- Onglet Relations : test adapté au type (Welch / ANOVA / χ^2 / Pearson+Spearman)
- Onglet Corrélations : heatmap matrice complète avec valeurs
- Onglet Export : téléchargement des données nettoyées en CSV

Comment interpréter les résultats

■ Onglet Qualité : plus de 20% de valeurs manquantes sur une colonne clé doit alerter sur la fiabilité des analyses qui l'utilisent. Skewness > 1 ou < -1 indique une forte asymétrie — envisager une transformation log. V de Cramér > 0.3 indique une association substantielle entre deux variables catégorielles. Shapiro-Wilk $p > 0.05$: pas d'écart significatif à la normalité à ce seuil.

Erreurs fréquentes à éviter

■ Ne pas vérifier l'encodage du fichier : les accents et noms d'espèces peuvent être corrompus si le fichier UTF-8 est ouvert en Latin-1.

■ Confondre N outliers IQR et N outliers $Z > 3$: sur une distribution asymétrique, l'IQR est plus robuste et doit être préféré.

■ Appliquer Pearson sans visualiser la relation : une corrélation de Pearson nulle n'exclut pas une relation non linéaire forte.

Importance en écologie et conservation

Réduit la barrière d'entrée pour les étudiants sans compétences en programmation. Centralise la validation de la qualité des données, étape souvent négligée qui conduit à des analyses incorrectes. Idéal pour des TP avec données de terrain réelles.

Référence clé

Wickham, H. & Grolemund, G. (2017). R for Data Science. O'Reilly Media, Sebastopol.

5.3. Corrélation et régression

Description

Quantifie et visualise la relation linéaire entre deux variables continues. Propose la régression linéaire simple (OLS) avec nuage de points, droite ajustée et intervalle de confiance à 95%. Affiche un graphique de résidus pour diagnostiquer l'homoscédasticité et la linéarité. Calcule le coefficient de Pearson r , le coefficient de détermination R^2 , et teste la significativité de la pente.

Fondements méthodologiques

Régression par Moindres Carrés Ordinaires (OLS) : minimise $SSE = \sum((y_i - \hat{y}_i)^2)$. Pente et intercept estimés analytiquement. Test de la pente : $t = b1 / SE(b1)$ suivant une loi de Student à $n-2$ degrés de liberté. IC 95% de la droite calculé par propagation des erreurs : $\hat{y} \pm t_{\{0.025, n-2\}} * SE(\hat{y})$ avec SE variant le long de la droite. Guard : $n \geq 3$ observations valides et $std(X) > 0$.

```
b1 (pente) = sum((x_i - x_bar)(y_i - y_bar)) / sum((x_i - x_bar)^2)
b0 (intercept) = y_bar - b1 * x_bar
R^2 = 1 - SSE/SST où SST = sum((y_i - y_bar)^2)
SE(b1) = sqrt(MSE / sum((x_i - x_bar)^2))
t = b1 / SE(b1) ~ Student(n-2) sous H0 : b1 = 0
```

Algorithme pas à pas

- Validation : $n \geq 3$ observations valides, $std(X) \neq 0$
- Calcul OLS via `scipy.stats.linregress(x, y)`
- Construction de la droite ajustée sur 200 points (grille régulière)
- Calcul des résidus : $e_i = y_i - (b0 + b1*x_i)$
- Tracé nuage de points + droite + bande IC 95%
- Tracé résidus vs valeurs ajustées pour diagnostic

Application ornithologique

Applications : relation masse-envergure (allométrie), régression du succès reproducteur sur la date de ponte (phénologie climatique), abondance en fonction de la surface d'habitat (écologie du paysage), longueur du tarse en fonction de l'altitude de nidification (gradient altitudinal).

Paramètres d'entrée	Sorties et résultats
• Variable explicative X (continue) • Variable réponse Y (continue) • Mode simulation : n individus, bruit gaussien, graine aléatoire	• $b0$ (intercept) et $b1$ (pente) avec erreurs-type et p-values • R^2 et coefficient de Pearson r • Nuage de points + droite de régression + bande IC 95% • Graphique des résidus vs valeurs ajustées • Export PDF du résumé statistique

Comment interpréter les résultats

■ R^2 proche de 1 : la relation linéaire explique bien la variabilité de Y. R^2 proche de 0 : la relation linéaire est faible (mais une relation non linéaire peut exister — vérifier le nuage). Résidus en entonnoir = hétéroscédasticité (variance croissante avec $\hat{Y}$). Résidus en courbe = relation non linéaire : envisager une transformation (log, racine).

Erreurs fréquentes à éviter

■ Extrapoler hors du domaine des données : la droite peut prédire des masses négatives ou biologiquement impossibles hors de la plage observée.

■ Ignorer le diagnostic des résidus : un R^2 élevé n'implique pas un bon ajustement si les résidus montrent un pattern systématique.

■ Appliquer une régression OLS quand Y est un comptage (entier ≥ 0) : utiliser le GLM Poisson qui est le modèle adapté.

Importance en écologie et conservation

La régression linéaire est l'outil statistique le plus utilisé en écologie. Comprendre ses hypothèses (linéarité, normalité des résidus, homoscedasticité, indépendance) et les diagnostiquer via les graphiques de résidus est essentiel pour produire des conclusions biologiques fiables et reproductibles.

Référence clé

Zar, J.H. (2010). Biostatistical Analysis, 5th ed. Prentice Hall, Upper Saddle River.

5.4. Tests statistiques

Description

Compare des groupes d'oiseaux selon une variable quantitative continue. Pour deux groupes : t-test de Welch (paramétrique) et Mann-Whitney U (non paramétrique). Pour 3 à 6 groupes : ANOVA unidirectionnelle et Kruskal-Wallis. Inclut des tests de normalité (Shapiro-Wilk) avec graphiques Q-Q pour chaque groupe, et calcul des tailles d'effet (d de Cohen, η^2).

Fondements méthodologiques

Normalité (Shapiro-Wilk) : H_0 = distribution normale, recommandé pour $n < 50$. t-test de Welch : compare deux moyennes sans supposer l'égalité des variances (degrés de liberté de Welch-Satterthwaite, fractionnaires). Mann-Whitney U : test non paramétrique sur les rangs, robuste aux outliers. ANOVA : $F = MS_{\text{between}} / MS_{\text{within}}$ (rapporte à la variabilité intra-groupe). Kruskal-Wallis : extension non paramétrique de l'ANOVA sur les rangs. Guard : au moins 2 groupes avec ≥ 2 observations chacun avant ANOVA/Kruskal.

Welch t : $t = (x1_bar - x2_bar) / \sqrt{s1^2/n1 + s2^2/n2}$

Cohen d : $d = (x1_bar - x2_bar) / s_{\text{pooled}}$

ANOVA F : $F = [SS_{\text{between}} / (k-1)] / [SS_{\text{within}} / (n-k)]$

```
eta² : eta² = SS_between / SS_total [0.01 faible, 0.06 moyen, 0.14 fort]
Kruskal H: H = (12 / n(n+1)) * sum(R_j² / n_j) - 3(n+1)
```

Algorithme pas à pas

- Test de Shapiro-Wilk par groupe (scipy.stats.shapiro)
- Tracé des graphiques Q-Q (scipy.stats.probplot) par groupe
- Si 2 groupes : Welch t-test + Mann-Whitney U + d de Cohen
- Si k groupes : ANOVA (f_oneway) + Kruskal-Wallis + eta² (SS_between/SS_total)
- Guard ANOVA/Kruskal : len(valid_series) >= 2
- Interprétation automatique de la significativité et de la taille d'effet

Application ornithologique

Comparer la masse entre mâles et femelles, le succès de nidification entre habitats (forêt / bocage / zone humide), l'abondance entre saisons ou années, la longueur du tarse entre populations géographiques. Fondamental pour valider des différences biologiques avant de les interpréter écologiquement.

Paramètres d'entrée

- Variable numérique à comparer
- Variable de groupement (2 à 6 modalités)
- Mode simulation ou CSV

Sorties et résultats

- Tableau Shapiro-Wilk : W et p-value par groupe
- Graphiques Q-Q par groupe (max 4)
- Statistique t / F / H, degrés de liberté, p-value
- Taille d'effet : d de Cohen (2 groupes) ou eta² (k groupes)
- Boîtes à moustaches comparatives avec annotation significativité

Comment interpréter les résultats

■ $p < 0.05$: différence statistiquement significative. d de Cohen : 0.2 = faible, 0.5 = modéré, 0.8 = fort. eta² : 0.01 = faible, 0.06 = modéré, 0.14 = fort. Si Welch significatif mais Mann-Whitney non : inspecter les valeurs aberrantes. Si Kruskal-Wallis significatif : des tests de Dunn post-hoc (correction Bonferroni) sont nécessaires pour identifier les paires différentes.

Erreurs fréquentes à éviter

- Se fier uniquement à la p-value sans la taille d'effet : avec $n = 1000$ oiseaux, une différence de 0.1 g peut être très significative mais biologiquement nulle.
- Réaliser de multiples comparaisons sans correction : 20 tests à $\alpha = 0.05$ génèrent en espérance 1 faux positif — appliquer la correction de Bonferroni.

■ Ignorer le test de normalité avant le t-test : avec $n < 20$ et distribution asymétrique, les conclusions du test paramétrique sont non fiables.

Importance en écologie et conservation

Les tests statistiques sont l'épine dorsale de l'écologie quantitative. Enseigner les tests paramétriques et non paramétriques avec vérification des hypothèses forme des scientifiques rigoureux capables de choisir le test adapté à leurs données plutôt que d'appliquer mécaniquement le t-test dans tous les contextes.

Référence clé

Sokal, R.R. & Rohlf, F.J. (2012). Biometry, 4th ed. W.H. Freeman, New York.

5.5. GLM pour données de comptage

Description

Modélise des données de comptage d'oiseaux (entiers non négatifs) avec un GLM Poisson ou Binomial Négatif. Contrôle simultanément pour l'habitat, la tendance temporelle et l'effort d'observation (offset). Compare les deux familles par AIC. Interprète les coefficients en Incidence Rate Ratio (IRR = $\exp(\beta)$). Propose des graphiques de diagnostics des résidus de Pearson.

Fondements méthodologiques

GLM Poisson : $\log(E[Y]) = X\beta + \log(\text{effort})$. Vérification surdispersion : $\phi = \chi^2_{\text{Pearson}} / \text{df}$. Si $\phi \gg 1$, le Binomial Négatif est plus approprié. BN : $\text{Var}(Y) = \mu + \mu^2/r$ (paramètre de dispersion r estimé). Estimation par Maximum de Vraisemblance (IRLS : moindres carrés itérés reponderés). $\text{AIC} = -2\log(L) + 2k$. $\text{IRR}_j = \exp(\beta_j)$: multiplicateur de l'abondance.

```
Poisson : log(mu_i) = beta_0 + beta_1*X1_i + ... + log(effort_i)
IRR_j = exp(beta_j) [multiplicateur pour une unité de X_j]
Surdispersion : phi = sum((y_i - mu_i)^2 / mu_i) / (n - p)
AIC = -2 * log(L_max) + 2 * k [k = nombre de paramètres]
BN Variance : Var(Y) = mu + mu^2/r [r -> inf converge vers Poisson]
```

Algorithme pas à pas

- Validation des colonnes (comptages ≥ 0 , habitat catégoriel)
- Ajustement GLM Poisson (`statsmodels.formula.api.glm, family=Poisson`)
- Calcul du ratio de surdispersion ϕ
- Ajustement GLM Binomial Négatif (`NegativeBinomial`)
- Comparaison AIC Poisson vs BN avec recommandation automatique
- Tableau IRR avec IC 95% via $\exp(\text{coef} \pm 1.96 \cdot \text{SE})$
- Graphiques diagnostics : résidus Pearson vs ajustés + Q-Q

Application ornithologique

Standard pour les comptages sur points d'écoute (IPA, STOC-EPS), relevés de transects ou points fixes. Permet de séparer l'effet habitat de l'effet année tout en corrigeant pour des efforts d'écoute variables. La surdispersion est quasi-universelle dans les comptages d'oiseaux (agrégation spatiale) : le Binomial Négatif est souvent nécessaire.

Paramètres d'entrée	Sorties et résultats
• Colonne de comptages (entiers ≥ 0) • Colonne habitat (catégorielle) • Colonne année ou session (numérique) • Colonne effort d'observation (offset, ex. durée en minutes)	• Tableau IRR avec IC 95% et p-values pour chaque prédicteur • AIC Poisson vs Binomial Négatif avec recommandation • Ratio de surdispersion ϕ • Graphiques de résidus de Pearson vs valeurs ajustées et Q-Q

Comment interpréter les résultats

■ IRR = 1.5 pour l'habitat Forêt (référence = Champ) signifie : abondance 1.5x plus élevée en forêt, toutes choses égales. IRR = 0.7 pour l'année signifie : déclin de 30% par an. $\phi > 2$ confirme une surdispersion : le GLM Poisson sous-estime les erreurs-type, produisant de faux positifs. $\phi > 10$: envisager le BN ou un modèle à inflation de zéros.

Erreurs fréquentes à éviter

■ Utiliser la régression OLS sur des comptages : résidus non normaux, prédictions négatives possibles, p-values incorrectes.

■ Ignorer la surdispersion ($\phi \gg 1$) : les erreurs-type Poisson sont sous-estimées — utiliser le BN ou la quasi-Poisson.

■ Omettre l'offset : sans correction pour l'effort, les sites visités plus longtemps paraissent artificiellement plus riches en espèces.

Importance en écologie et conservation

Les comptages d'oiseaux violent systématiquement les hypothèses de la régression linéaire. Le GLM est le modèle adéquat et son enseignement est indispensable pour analyser les données des programmes de surveillance long terme (STOC, BBS, Wetland Bird Survey) qui produisent les indicateurs de l'état de l'avifaune utilisés par les politiques de conservation.

Référence clé

McCullagh, P. & Nelder, J.A. (1989). Generalized Linear Models, 2nd ed. Chapman & Hall.

BIOSTATISTIQUE

5.6. Modèle mixte — LMM

Description

Modèle Linéaire Mixte (LMM) séparant les effets fixes (prédicteurs biologiques) des effets aléatoires (sites, individus, sessions de baguage). Estime le coefficient de corrélation intraclasse (ICC) quantifiant la part de variance due au groupement. Affiche les composantes de variance et les effets fixes avec erreurs-type. Utilise l'estimateur REML non biaisé pour les composantes de variance.

Fondements méthodologiques

Modèle : $y_{ij} = \beta_0 + \beta_1 x_{ij} + b_j + \epsilon_{ij}$, avec $b_j \sim N(0, \sigma^2_b)$ et $\epsilon_{ij} \sim N(0, \sigma^2)$. Estimation par REML (Restricted Maximum Likelihood) : non biaisé pour σ^2_b contrairement au ML classique, recommandé pour estimer les composantes de variance. $ICC = \sigma^2_b / (\sigma^2_b + \sigma^2)$. Un $ICC > 0.1$ justifie le LMM. Implémenté via `statsmodels.formula.api.mixedlm`.

```
LMM : y_ij = (beta_0 + beta_1*x_ij) + b_j + epsilon_ij
b_j ~ N(0, sigma^2_b) [effet aléatoire groupe j]
```

```
epsilon_ij ~ N(0, sigma^2_e) [résidu intra-groupe]
ICC = sigma^2_b / (sigma^2_b + sigma^2_e)
REML : maximise la vraisemblance des contrastes orthogonaux aux effets fixes
```

Algorithme pas à pas

- Extraction des colonnes par valeurs numpy (évite collisions de noms)
- Validation : ≥ 2 groupes distincts, ≥ 5 observations, X non constante
- Ajustement LMM par REML : `mixedlm('_Y ~ _X', sub, groups).fit(reml=True)`
- Extraction des effets fixes tronqués à `n_fe = len(fe_params)`
- SE depuis `bse_fe` ou `bse[:n_fe]` selon version statsmodels (0.14+)
- Calcul ICC, AIC (avec fallback $-2 \cdot \text{llf} + 2 \cdot k$ si NaN), `n_groups`
- Nuage de points coloré par groupe + droite d'effet fixe global

Application ornithologique

Indispensable pour les données de morphométrie collectées sur plusieurs sites (effet site = variation entre localités), les suivis comportementaux avec individus mesurés plusieurs fois, les données de baguage avec passagers à sessions répétées. Un ICC > 0.1 signifie qu'ignorer la structure groupée gonfle les degrés de liberté et produit des p-values trop optimistes (taux de faux positifs $> 5\%$).

Paramètres d'entrée	Sorties et résultats
• Variable réponse Y (numérique continue) • Prédicteur fixe X (numérique) • Variable de groupement G (catégorielle, effet aléatoire)	• Tableau effets fixes : coef., SE, z, p-value pour Intercept et X • Composantes de variance : σ^2_b (entre groupes) et σ^2_e (résiduelle) • ICC et AIC du modèle • Nuage de points coloré par groupe + droite d'effet fixe global • Graphique des résidus vs valeurs ajustées

Comment interpréter les résultats

■ ICC proche de 0 : peu de variance expliquée par le groupement, OLS suffisant. ICC > 0.1 : le groupement explique plus de 10% de la variance — LMM justifié. ICC > 0.5 : structure de groupe très forte ; les effets fixes nécessitent beaucoup de groupes pour être bien estimés. La pente `beta_1` est l'effet de X net de la variabilité inter-groupes.

Erreurs fréquentes à éviter

- Utiliser ML au lieu de REML pour estimer les composantes de variance : ML sous-estime σ^2_b , particulièrement avec peu de groupes (< 10).
- Traiter le groupe comme effet fixe quand il représente un échantillon d'une population de groupes possibles : l'effet aléatoire est plus approprié et plus parcimonieux.

■ Ignorer l'ICC et utiliser OLS sur données groupées : les erreurs-type des effets fixes sont sous-estimées, produisant un taux de faux positifs > 5%.

Importance en écologie et conservation

La plupart des données ornithologiques de terrain sont groupées (par site, transect, colonie ou individu). Le LMM est la solution standard en écologie moderne pour respecter la structure des données. Son enseignement est indispensable dans tout cursus de biostatistique appliquée à l'ornithologie.

Référence clé

Zuur, A.F. et al. (2009). Mixed Effects Models and Extensions in Ecology with R. Springer.

5.7. Domaine vital — MCP

Description

Calcule le Minimum Convex Polygon (MCP) à partir de localisations GPS individuelles. Le MCP est le plus petit polygone convexe contenant X% des localisations d'un individu, paramétrable de 50% à 100%. Propose une carte interactive avec superposition des points et des polygones, et un tableau comparatif des aires MCP par individu et par percentile.

Fondements méthodologiques

Algorithme : (1) calculer le centroïde de toutes les localisations, (2) calculer les distances euclidiennes de chaque point au centroïde, (3) trier par distance croissante, (4) conserver les X% points les plus proches, (5) calculer l'enveloppe convexe via `scipy.spatial.ConvexHull`. L'aire correspond à `ConvexHull.volume` en 2D. Note : les coordonnées doivent être en projection métrique pour des aires en ha.

```
Centroïde : (x_c, y_c) = (mean(x_i), mean(y_i))
Distance : d_i = sqrt((x_i - x_c)2 + (y_i - y_c)2)
MCP X% : sélectionner les X/100 * n points les plus proches du centroïde
Aire MCP = ConvexHull(points_selectionnees).volume [unités : coords2]
```

Algorithme pas à pas

- Chargement des colonnes X (lon) et Y (lat) par identifiant individuel
- Calcul du centroïde par individu
- Tri des localisations par distance euclidienne au centroïde
- Sélection du percentile choisi (50%, 75%, 90%, 95%, 100%)
- Calcul de l'enveloppe convexe (`scipy.spatial.ConvexHull`)
- Tracé interactif Plotly : points colorés par individu + polygone MCP
- Tableau des aires par individu et par percentile

Application ornithologique

Utilisé pour estimer le domaine vital de rapaces (busard, milan, épervier), cigognes, limicoles en nidification, passereaux équipés de balises GPS légères (< 3% de la masse corporelle). Permet de comparer les domaines vitaux entre sexes, classes d'âge ou saisons, et d'identifier les zones d'habitat critiques.

Paramètres d'entrée	Sorties et résultats
• Colonne X (longitude) et Y (latitude) — coordonnées décimales ou métriques • Colonne identifiant individuel • Percentile MCP (50%, 75%, 90%, 95%, 100%)	• Carte interactive Plotly avec points et polygone MCP par individu • Tableau : N localisations totales, N utilisées, aire MCP par individu • Graphique de comparaison des aires entre individus

Comment interpréter les résultats

■ MCP 95% : domaine vital usuel, excluant 5% des localisations les plus excentrées (déplacements exceptionnels ou erreurs GPS). MCP 50% : zone cœur de l'activité principale. La taille du MCP augmente avec le nombre de localisations jusqu'à saturation : au moins 30 à 50 localisations sont recommandées pour un MCP stable.

Erreurs fréquentes à éviter

■ Comparer des MCP avec des effectifs de localisations très différents : un individu avec 100 points aura un MCP systématiquement plus grand qu'un individu avec 20 points, même si leurs territoires sont identiques.

■ Utiliser le MCP 100% pour comparer des individus : une seule localisation extrême (erreur GPS) peut doubler la surface estimée.

■ Calculer des superficies en degrés décimaux sans conversion métrique : convertir en projection UTM pour des aires comparables en hectares.

Importance en écologie et conservation

Le MCP est la méthode de référence historique pour le domaine vital (Mohr 1947). Sa simplicité en fait un excellent outil pédagogique pour introduire les concepts d'utilisation de l'espace avant le KDE plus sophistiqué. Largement utilisé pour délimiter des zones tampons autour des nids dans les rapports d'évaluation d'impact.

Référence clé

Mohr, C.O. (1947). Table of equivalent populations of North American small mammals. American Midland Naturalist 37(1): 223-249.

BIOSTATISTIQUE

5.8. Domaine vital — KDE

Description

Estime le domaine vital par Kernel Density Estimation (KDE) bivarié : construit une surface de densité de probabilité à partir des localisations GPS et extrait des isopleths (contours de probabilité) à 50%, 75%, 90%, 95% et 99%. Le bandwidth est estimé automatiquement par la règle de Scott, ajustable via un multiplicateur. L'isopleth 95% représente le domaine vital usuel, le 50% la zone cœur d'utilisation préférentielle.

Fondements méthodologiques

Estimateur à noyau gaussien bivarié : $\hat{f}(x,y) = (1/(n \cdot h^2)) \cdot \sum (K((x-x_i)/h, (y-y_i)/h))$. Bandwidth par règle de Scott : $h = n^{-(1/6)} \cdot \sigma_{\hat{}}$. Ce bandwidth est optimal pour une distribution gaussienne bivariée, tendant à sur-lisser les distributions complexes. Isopleth X% : seuil de densité t tel que la proportion de la masse de probabilité au-dessus de t soit $X/100$. Implémenté avec `scipy.stats.gaussian_kde`.

```

KDE :  $\hat{f}(x) = (1/n) * \sum K_h(x - x_i)$ 
 $K_h(u) = (1/h^2) * K(u/h)$  [noyau gaussien bivarié]
Scott h :  $h = n^{(-1/6)} * \sigma_{\hat{h}}$  [sélection automatique du bandwidth]
Isoleth X% : trouver t tel que  $\int_{f(x)>t} f(x) dx = X/100$ 

```

Algorithme pas à pas

- Chargement des localisations et séparation par individu
- Calcul du bandwidth par règle de Scott * facteur multiplicatif utilisateur
- Évaluation du KDE sur une grille 100x100 (scipy.stats.gaussian_kde)
- Calcul des seuils de densité pour chaque isopleth sélectionné
- Extraction des contours par interpolation et calcul des aires
- Tracé heatmap de densité + contours isopleths superposés
- Tableau des aires par individu et par isopleth

Application ornithologique

Standard actuel en écologie du mouvement pour les oiseaux équipés de GPS ou balises PTT Argos. Utilisé pour identifier les habitats critiques, couloirs migratoires, zones de reproduction et d'hivernage. Supérieur au MCP pour les espèces aux mouvements asymétriques (migration) ou multimodaux (plusieurs zones de ressources). Requis dans les études d'impact éolien.

Paramètres d'entrée	Sorties et résultats
• Colonne X (longitude) et Y (latitude) des localisations GPS • Colonne identifiant individuel • Facteur de lissage : multiplicateur de Scott (0.1 à 2.0) • Isopleths souhaités : 50%, 75%, 90%, 95%, 99%	• Heatmap de densité KDE par individu (onglets séparés) • Contours isopleths colorés en surimpression • Tableau des aires par isopleth et par individu • Comparaison des zones cœur (50%) et domaine complet (95%)

Comment interpréter les résultats

■ Zone cœur 50% : utilisation préférentielle (gîte, alimentation principale). Domaine vital 95% : zone d'utilisation régulière, hors déplacements exceptionnels. Facteur < 1 (ex. 0.6) : moins de lissage, meilleure résolution, risque de sur-ajustement si peu de localisations. Facteur > 1 (ex. 1.5) : plus de lissage, zones fusionnées, utile pour distributions étalées.

Erreurs fréquentes à éviter

- Utiliser la règle de Scott sans ajustement pour des distributions bimodales : les deux modes (ex. deux zones d'alimentation) peuvent être artificiellement fusionnés — réduire le facteur à 0.5-0.7.
- Comparer des KDE entre individus avec des effectifs de localisations très différents : le KDE est sensible à n pour les petits effectifs (n < 30).

■ Interpréter les isopleths comme des limites strictes de territoire : ils représentent des probabilités d'utilisation, non des frontières.

Importance en écologie et conservation

Le KDE est la méthode de choix en recherche contemporaine sur le domaine vital (> 80% des publications récentes). Comprendre le rôle du bandwidth et l'interprétation des isopleths est fondamental pour tout projet de radio-pistage ou de GPS-tracking ornithologique.

Référence clé

Silverman, B.W. (1986). Density Estimation for Statistics and Data Analysis. Chapman and Hall, London.

Section 6 — Dynamique des populations (10 modules)

DYNAMIQUE DES POPULATIONS

6.1. Richesse spécifique et diversité

Description

Calcule et compare les indices de diversité alpha d'une communauté d'oiseaux : richesse spécifique (S), indice de Shannon (H'), indice de Simpson (1-D), équitabilité de Pielou (J'), et courbes d'accumulation d'espèces (raréfaction) avec intervalles de confiance à 95% par randomisation.

Fondements méthodologiques

Shannon : $H' = -\sum(p_i * \ln(p_i))$ avec $p_i = n_i / N$ (proportion de l'espèce i). Simpson : $D = \sum(p_i^2)$; l'indice affiché est 1-D (diversité). Pielou : $J' = H' / \ln(S)$ (0 = une espèce domine, 1 = toutes égales). Courbe d'accumulation : 50 randomisations de l'ordre des sites, calcul du nombre moyen d'espèces observées en fonction du nombre de sites cumulés. IC 95% par percentiles (2.5% et 97.5%) des 50 réplifications.

```
Shannon : H' = -sum(p_i * ln(p_i)) [bits si log2, nats si ln]
Simpson : D = sum(p_i^2) ; Diversité = 1 - D
Pielou : J' = H' / ln(S) [0 = mono-dominance, 1 = équitabilité parfaite]
S = nombre total d'espèces observées (richesse spécifique)
```

Algorithme pas à pas

- Lecture de la matrice sites x espèces (ou CSV avec colonnes = espèces)
- Calcul de S, H', D, J' pour chaque site
- Comparaison graphique des indices entre sites (barres groupées)
- Randomisation de l'ordre des sites pour la courbe d'accumulation (50 itérations)
- Calcul de la richesse cumulée moyenne et des percentiles 2.5% et 97.5%
- Affichage de la courbe d'accumulation avec bande d'IC 95%

Application ornithologique

Utilisé pour comparer la diversité des communautés d'oiseaux entre habitats (forêt vs lisière vs champ), entre saisons (hivernage vs reproduction), ou entre zones protégées et non protégées. Outil de base pour les évaluations écologiques des plans de gestion et études d'impact Natura 2000.

Paramètres d'entrée

Sorties et résultats

- Matrice sites x espèces (colonnes = espèces, valeurs = abondances)
- Ou CSV avec une colonne par espèce et une ligne par site
- Nombre d'itérations pour la courbe d'accumulation (défaut : 50)
- Indices S, H', 1-D, J' par site dans un tableau récapitulatif
- Histogrammes comparatifs des indices entre sites
- Courbe d'accumulation d'espèces avec IC 95%
- Interprétation automatisée de l'équitabilité

Comment interpréter les résultats

■ H' proche de $\ln(S)$ = communauté équitale (toutes les espèces également abondantes). H' faible = communauté dominée par une ou quelques espèces. J' > 0.8 : bonne équitabilité. J' < 0.5 : forte dominance. Une courbe d'accumulation qui atteint un plateau indique que le nombre de sites est suffisant pour estimer S — sinon : richesse sous-estimée par manque d'échantillonnage.

Erreurs fréquentes à éviter

- Comparer H' entre sites avec des effectifs totaux très différents : H' est sensible au n total — raréfier les données au même effectif avant comparaison.
- Confondre richesse spécifique (S) et diversité (H') : S ne tient pas compte des abondances relatives.
- Interpréter J' = 1 comme une communauté 'optimale' : une communauté avec 2 espèces à abondances égales a J' = 1 mais une diversité très faible.

Importance en écologie et conservation

La diversité aviaire est un indicateur reconnu de l'intégrité écologique. Ces indices sont utilisés dans les rapports d'impact environnemental, les évaluations Natura 2000, les plans de gestion des réserves naturelles, et le calcul des indicateurs nationaux de l'Observatoire de la Biodiversité.

Référence clé

Shannon, C.E. & Weaver, W. (1949). The Mathematical Theory of Communication. University of Illinois Press.

**DYNAMIQUE
DES
POPULATIONS**

6.2. Croissance exponentielle et logistique

Description

Simule et compare deux modèles de croissance de population : la croissance exponentielle (Malthus, densité-indépendante) et la croissance logistique (Verhulst, densité-dépendante) avec contrôle du taux d'accroissement intrinsèque r et de la capacité de charge K. Visualise la convergence vers K et calcule le temps de doublement.

Fondements méthodologiques

Exponentielle : $N(t) = N_0 * \exp(r*t)$ — croissance illimitée, pas de régulation. Logistique : $dN/dt = r*N*(1 - N/K)$. Solution analytique : $N(t) = K / (1 + ((K-N_0)/N_0) * \exp(-r*t))$. La densité-dépendance est encodée par le terme freinage $(1 - N/K)$. Temps de doublement (phase exponentielle) : $T_d = \ln(2) / r$.

```
Exponentielle : N(t) = N0 * exp(r * t)
Logistique : N(t) = K / (1 + ((K - N0)/N0) * exp(-r * t))
dN/dt = r * N * (1 - N/K) [terme de freinage densité-dépendant]
Temps de doublement : T_d = ln(2) / r
Point d'inflexion logistique : N = K/2 (croissance maximale)
```

Algorithme pas à pas

- Calcul de $N(t)$ exponentielle analytiquement pour $t = 0, 1, \dots, T$
- Calcul de $N(t)$ logistique analytiquement
- Tracé comparatif des deux courbes $N(t)$
- Affichage de K , T_d , et $N(T)$ pour les deux modèles
- Interprétation automatisée : phase de croissance vs saturation

Application ornithologique

Compréhension de la dynamique de récupération après un déclin (bécasse, spatule, outarde), croissance d'une population réintroduite (vautour fauve, cigogne blanche), impact d'une chasse sur une population à l'équilibre. Fondement conceptuel de tous les modèles de gestion cynégétique (grouse, faisan, perdrix).

Paramètres d'entrée	Sorties et résultats
• Population initiale N_0 • Taux d'accroissement intrinsèque r (positif = croissance) • Capacité de charge K • Durée de simulation T (années)	• Courbes $N(t)$ exponentielle et logistique superposées • Temps de doublement T_d • N final pour les deux modèles • Marqueur de K sur le graphique

Comment interpréter les résultats

■ $r > 0$: population croissante. $r = 0$: population stable. $r < 0$: déclin. La logistique converge vers K quel que soit N_0 (si $r > 0$). Le point d'inflexion ($N = K/2$) est le moment de croissance absolue maximale — c'est ici que le rendement durable maximal (MSY) est atteint. L'exponentielle diverge toujours — impossible biologiquement sur le long terme.

Erreurs fréquentes à éviter

- Confondre r (taux intrinsèque) et λ (ratio fini) : $r = \ln(\lambda)$. Une population avec $\lambda = 0.95$ a $r = -0.051$ (déclin de 5% par an).
- Appliquer le modèle logistique simple à des espèces à vie longue : la densité-dépendance est souvent retardée (time-lag) dans ces espèces.

■ Interpréter la phase initiale d'une logistique comme une exponentielle réelle : la régulation par K existe dès $N_0 > 0$ mais n'est visible qu'à N proche de K .

Importance en écologie et conservation

Les modèles de croissance sont le fondement de la dynamique des populations. La distinction entre croissance densité-indépendante et densité-dépendante est essentielle pour dimensionner les efforts de conservation et comprendre les mécanismes de régulation naturelle des populations aviaires.

Référence clé

Verhulst, P.F. (1838). Notice sur la loi que la population suit dans son accroissement. Correspondance Mathématique et Physique 10: 113-121.

6.3. Matrices de Leslie

Description

Projette une population féminine structurée en classes d'âge à partir d'une matrice de Leslie intégrant fécondités et probabilités de survie. Calcule la valeur propre dominante λ (taux de croissance asymptotique), la distribution d'âge stable, les valeurs reproductives, et les matrices de sensibilité et d'élasticité permettant d'identifier les leviers démographiques clés.

Fondements méthodologiques

Projection : $N(t+1) = A * N(t)$ avec A matrice de Leslie (fécondités en ligne 0, survies en sous-diagonale). Valeur propre dominante λ_1 via `np.linalg.eig(A)`. Distribution stable : vecteur propre droit w normalisé (N à long terme). Valeurs reproductives : vecteur propre gauche v de A^T (contribution reproductive). Sensibilité : $S_{ij} = (v_i * w_j) / \lambda$. Elasticité : $e_{ij} = (a_{ij} / \lambda) * S_{ij}$. Propriété : $\sum(e_{ij}) = 1$.

```
Projection : N(t+1) = A * N(t)
Lambda : valeur propre dominante de A (lambda > 1 : croissance)
Sensibilité : S_ij = delta(lambda) / delta(a_ij) = v_i * w_j /
Elasticité : e_ij = (a_ij / lambda) * S_ij
Propriété : sum_ij(e_ij) = 1 [les élasticités somment à 1]
```

Algorithme pas à pas

- Construction de la matrice A depuis les fécondités et survies saisies
- Décomposition en valeurs propres via `numpy.linalg.eig(A)`
- Extraction du vecteur propre droit w (distribution stable) normalisé
- Calcul du vecteur propre gauche v de A^T (valeurs reproductives)
- Calcul des matrices de sensibilité et d'élasticité
- Projection temporelle $N(t)$ sur T années
- Visualisation : courbes $N(t)$ par classe, barres distribution stable, heatmaps

Application ornithologique

Outil de référence pour la gestion d'espèces à vie longue : rapaces (vautour moine, aigle royal), grands plongeurs, puffins, albatros. L'élasticité de la survie adulte est généralement la plus élevée chez ces espèces, orientant les priorités de conservation vers la réduction de la mortalité adulte (captures accessoires, empoisonnements, collision éolienne).

Paramètres d'entrée

Sorties et résultats

- Fécondités par classe d'âge ($F_0, F_1, \dots, F_n$)
- Probabilités de survie inter-classes ($S_0, S_1, \dots, S_{n-1}$)
- Population initiale par classe d'âge
- Durée de projection (années)
- Courbes de projection $N(t)$ par classe d'âge
- λ dominant avec interprétation (croissance / déclin / stabilité)
- Distribution d'âge stable (barres normalisées)
- Valeurs reproductives par classe (importance de chaque classe)
- Heatmaps de sensibilité et d'élasticité

Comment interpréter les résultats

■ $\lambda > 1$: population en croissance ($\lambda = 1.05 = +5\%$ par an). $\lambda < 1$: population en déclin ($\lambda = 0.95 = -5\%$ par an). $\lambda = 1$: population stable. L'élasticité la plus élevée indique le paramètre démographique à cibler en priorité. Pour les rapaces : améliorer la survie adulte (e élevée) est plus efficace qu'améliorer la fécondité (e faible).

Erreurs fréquentes à éviter

- Supposer que la distribution d'âge initiale est la distribution stable : la projection converge vers la distribution stable, mais les premières années reflètent la distribution initiale qui peut être très différente.
- Interpréter la sensibilité absolue sans considérer la plage biologique possible du paramètre : préférer l'élasticité pour les comparaisons.
- Appliquer une matrice de Leslie à une population bisexuée sans correction : le modèle ne projette que les femelles (ou les deux sexes si taux constant).

Importance en écologie et conservation

Les matrices de Leslie sont l'outil le plus puissant pour cibler les actions de conservation : l'élasticité indique quel paramètre démographique améliorer en priorité pour maximiser λ . Caswell (2001) reste la référence mondiale pour cette approche appliquée à la gestion des espèces menacées.

Référence clé

Caswell, H. (2001). Matrix Population Models, 2nd ed. Sinauer Associates, Sunderland, MA.

DYNAMIQUE

DES

POPULATIONS

6.4. Capture-Marquage-Recapture

Description

Estime l'abondance d'une population par l'estimateur de Lincoln-Petersen et sa correction non biaisée de Chapman. Calcule les intervalles de confiance à 95% par la méthode du log et le coefficient de variation. Illustre le principe de la détectabilité imparfaite et propose trois scénarios pédagogiques préconfigurés couvrant différents contextes ornithologiques.

Fondements méthodologiques

Lincoln-Petersen : $N_{\text{hat}} = (M * C) / R$. Correction Chapman (non biaisée pour petits R) : $N_{\text{hat}} = (M+1)*(C+1)/(R+1) - 1$. Variance de Chapman : $\text{Var} = (M+1)*(C+1)*(M-R)*(C-R) / ((R+1)^2*(R+2))$. IC 95% par méthode du log : $\exp(\log(N_{\text{hat}}) \pm 1.96 * \text{sqrt}(\text{Var}) / N_{\text{hat}})$. Hypothèses : population fermée, marquage sans effet, détectabilité homogène.

```
Lincoln-Petersen : N_hat = (M * C) / R
Chapman (non biaisé) : N_hat = (M+1)*(C+1) / (R+1) - 1
CV = sqrt(Var(N_hat)) / N_hat [coefficient de variation]
IC 95% log : exp( log(N_hat) ± 1.96 * SE_log )
```

Algorithme pas à pas

- Saisie ou simulation de M (marqués), C (capturés en 2ème session), R (recapturés)
- Calcul de N_{hat} par Lincoln-Petersen et Chapman
- Calcul de la variance, du CV et de l'IC 95%
- Graphique d'incertitude : $N_{\text{hat}} \pm \text{IC } 95\%$
- Interprétation automatisée de la précision (CV < 20% = acceptable)
- 3 scénarios préconfigurés : petite population / grande population / fort taux de recapture

Application ornithologique

Utilisé pour estimer les effectifs de passereaux (sessions de baguage printanières), de larolimicoles (captures-bagages sur vasières), de rapaces (piégeage-baguage). Permet d'obtenir une estimation absolue de l'abondance, contrairement aux IKA qui ne donnent qu'un indice relatif sans calibration.

Paramètres d'entrée	Sorties et résultats
• M : nombre d'individus capturés, marqués et relâchés (session 1) • C : nombre d'individus capturés en session 2 • R : nombre d'individus recapturés (portant déjà une marque) en session 2	• N_{hat} estimé par Lincoln-Petersen et Chapman • Intervalle de confiance 95% et coefficient de variation • Graphique d'incertitude de l'estimation • Interprétation de la précision de l'estimation

Comment interpréter les résultats

■ CV < 20% : estimation précise. CV 20-40% : estimation acceptable. CV > 40% : estimation très incertaine — augmenter l'effort de recapture. N_{hat} faible avec R/C élevé : population petite et bien détectée. N_{hat} élevé avec R/C faible : population grande ou détectabilité faible. La correction de Chapman réduit le biais quand R est petit (< 10).

Erreurs fréquentes à éviter

■ Violer l'hypothèse de population fermée : des mouvements entre sessions (émigration, immigration) biaisent N_{hat} . Réaliser les deux sessions en courte période (1-2 jours pour les passereaux).

■ Supposer une détectabilité homogène : si certains individus évitent les pièges (trap-shyness) ou les recherchent (trap-happiness), $N_{\hat{}}$ est biaisé.

■ Utiliser Lincoln-Petersen sans correction de Chapman quand R est très petit : biais important pour $R < 10$ — toujours utiliser Chapman.

Importance en écologie et conservation

L'estimation de l'abondance absolue est fondamentale pour évaluer l'état de conservation d'une population, dimensionner des programmes de réintroduction, et suivre les tendances dans le temps avec des estimations comparables. Les méthodes CMR sont enseignées dans tous les cursus d'écologie des populations.

Référence clé

Lincoln, F.C. (1930). Calculating Waterfowl Abundance on the Basis of Banding Returns. USDA Circular 118.

6.5. Modèles d'occupation

Description

Estime séparément la probabilité d'occupation (ψ) et la probabilité de détection (p) d'une espèce sur des sites visités plusieurs fois. Corrige le biais de l'occupation naïve (proportion de sites avec au moins une détection) dû à la détectabilité imparfaite. Modèle de MacKenzie et al. (2002, Ecology).

Fondements méthodologiques

Vraisemblance : $L(\psi, p | y) = \prod_i [\psi^{\sum_k y_{ik}} (1-\psi)^{K-\sum_k y_{ik}} + I(\sum_k y_{ik}=0) (1-\psi)]$. Pour un site i avec historique $y_{i1}, \dots, y_{iK}$ de K visites : si au moins une détection : contribue $\psi \cdot \prod(\text{termes détection})$. si jamais détecté : contribue $\psi(1-p)^K + (1-\psi)$. Estimation par Nelder-Mead en espace logit. Occupation naïve théorique : $\psi_{\text{naive}} = \psi \cdot (1 - (1-p)^K)$.

```
L(ψ, p | y) = prod_i [ ψ * p^d_i * (1-p)^(K-d_i) + I(d_i=0) * (1-ψ) ]
d_i = sum_k(y_ik) [nombre de détections au site i]
Occupation naïve : ψ_obs = proportion sites avec au moins 1 détection
Biais : ψ_naive sous-estime ψ si p < 1
Biais relatif = (ψ - ψ_naive) / ψ * 100%
```

Algorithme pas à pas

- Construction de l'historique de détections (matrice sites x visites, 0/1)
- Définition de la log-vraisemblance négative en espace logit(ψ), logit(p)
- Minimisation par Nelder-Mead (scipy.optimize.minimize)
- Back-transformation logit -> probabilités
- Calcul de l'occupation naïve et du biais de sous-estimation
- Avertissement si convergence extrême (ψ ou p proche de 0 ou 1)

Application ornithologique

Indispensable pour les espèces discrètes ou rares : rapaces nocturnes (chevêchette, effraie des clochers), pics, passereaux forestiers, limicoles à faible détection. Fondement des programmes de surveillance STOC, où l'absence apparente n'implique pas l'absence réelle de l'espèce.

Paramètres d'entrée	Sorties et résultats
• Historique de détection : matrice sites x visites (0 = absent/non détecté, 1 = détecté) • Ou paramètres de simulation : ψ vraie, p vraie, K visites, N sites	• ψ estimée (occupation corrigée), p estimée (détection) • Occupation naïve et biais de sous-estimation en % • Graphique comparatif ψ vraie / ψ estimée / ψ naïve • Avertissement si convergence sur la limite des paramètres

Comment interpréter les résultats

■ $\psi = 0.8$ et $p = 0.3$: 80% des sites sont occupés mais la détection est faible. ψ naïve = $0.8 * (1 - (1 - 0.3)^3) = 0.66$: si 3 visites, on observe seulement 66% d'occupation alors que 80% des sites sont réellement occupés. p proche de 0 avec K faible : biais très élevé — augmenter le nombre de visites. $p > 0.8$ avec $K = 3$: occupation naïve fiable.

Erreurs fréquentes à éviter

■ Utiliser l'occupation naïve sans correction quand $p < 1$: sous-estime systématiquement l'occupation réelle, menant à des conclusions erronées sur le statut de conservation.

■ Violer l'hypothèse d'indépendance conditionnelle entre sites : si la détection d'un individu voisin déclenche la détection, p est biaisée.

■ Appliquer le modèle avec $K = 1$ visite : impossible d'estimer p sans visites répétées — le modèle d'occupation exige $K \geq 2$.

Importance en écologie et conservation

L'occupation corrigée pour la détection est devenue le standard international pour les inventaires et suivis d'espèces. Ignorer p produit des estimations fortement biaisées et des conclusions incorrectes sur l'état de conservation. MacKenzie et al. (2002) est l'un des articles les plus cités en écologie.

Référence clé

MacKenzie, D.I. et al. (2002). Estimating site occupancy rates when detection probabilities are less than one. *Ecology* 83(8): 2248-2255.

DYNAMIQUE
DES
POPULATIONS

6.6. Distance sampling

Description

Estime la densité et l'abondance d'une population à partir des distances d'observation sur des transects linéaires. Ajuste une fonction de détection demi-normale par maximum de vraisemblance, calcule la largeur efficace du transect (ESW), la densité et l'abondance avec avertissement si plus de 50% des distances sont filtrées par la limite W .

Fondements méthodologiques

Fonction de détection demi-normale : $g(x) = \exp(-x^2 / (2 * \sigma^2))$. La probabilité de détection à distance x chute avec la distance. ESW (Effective Strip Width) : $\int_0^W g(x) dx = \sigma * \sqrt{\pi/2} * \text{erf}(W / (\sigma * \sqrt{2}))$. σ estimé par MLE (minimisation de $-\log(L)$ sur $\log(\sigma)$). Densité : $D = n / (2 * \text{ESW} * L_{\text{total}})$, avec L = longueur totale des transects.

```
g(x) = exp(-x^2 / (2 * sigma^2)) [fonction de détection demi-normale]
ESW = sigma * sqrt(pi/2) * erf(W / (sigma * sqrt(2)))
```

Densité : $D = n / (2 * ESW * L * K)$ [L = longueur transect, K = nb transects]
 Abondance : $N = D * A$ [A = superficie de la zone d'étude]
 MLE sigma : $\text{minimize } n * \log(ESW) + \sum(x_i^2) / (2 * \sigma^2)$

Algorithme pas à pas

- Filtrage des distances : $0 \leq x \leq W$ (avec avertissement si > 50% filtrées)
- Ajustement sigma par MLE (minimize_scalar sur log-sigma, bounds log-echelle)
- Calcul ESW = effective_strip_width(sigma, W)
- Calcul densité D et abondance N
- Tracé histogramme des distances + courbe $g(x)$ ajustée + ligne ESW

Application ornithologique

Méthode standard pour les comptages sur transect linéaire de passereaux, rapaces, larolimicoles. Utilisée dans le STOC-EPS, les inventaires Natura 2000, les études préalables aux projets d'aménagement (éoliennes, routes). Permet d'obtenir une densité absolue sans hypothèse sur la détectabilité à distance nulle ($g(0) = 1$ postulé).

Paramètres d'entrée

- Distances d'observation perpendiculaires au transect (m)
- Demi-largeur maximale W du transect (m)
- Longueur totale des transects (m)
- Nombre de transects

Sorties et résultats

- Sigma estimé (portée caractéristique de détection en m)
- ESW (Effective Strip Width en m)
- Densité estimée (ind/ha ou ind/km²)
- Histogramme des distances + courbe de détection $g(x)$
- Avertissement si > 50% des distances filtrées

Comment interpréter les résultats

■ ESW proche de W : $g(x)$ reste élevée sur toute la largeur — très bonne détectabilité. $ESW \ll W$: détectabilité chute rapidement avec la distance — sigma petit. Histogramme avec mode > 0 (pic non à la distance nulle) : problème de détection en bord de transect ou évation d'animaux. Densité en ind/ha : D = 5 ind/ha signifie 5 oiseaux pour 10000 m².

Erreurs fréquentes à éviter

■ Regrouper des espèces aux fonctions de détection différentes : ajuster un modèle séparé pour chaque espèce ou groupe fonctionnel.

■ Ne pas vérifier le pic à la distance zéro ($g(0) = 1$) : si les oiseaux fuient à l'approche, les distances proches sont sous-représentées et la densité est surestimée.

■ Utiliser W trop large : inclure des distances où $g(x) \approx 0$ ajoute du bruit sans information. Tronquer à $W = 2 * \sigma$ pour un bon ajustement.

Importance en écologie et conservation

Le distance sampling est l'une des méthodes les plus rigoureuses pour estimer des densités absolues en tenant compte de la détectabilité décroissante. Enseigné dans les formations LPO, Naturevolution et les cursus universitaires d'écologie. Buckland et al. (2001) est la référence fondamentale.

Référence clé

Buckland, S.T. et al. (2001). Introduction to Distance Sampling. Oxford University Press.

6.7. Lotka-Volterra

Description

Simule les interactions proie-prédateur selon le modèle classique de Lotka-Volterra. Visualise les oscillations cycliques dans le temps et le portrait de phase (cycle limite elliptique dans l'espace proie-prédateur). Permet d'explorer la stabilité du point d'équilibre et l'effet des paramètres sur la période et l'amplitude des oscillations.

Fondements méthodologiques

Système d'équations différentielles : $dN/dt = r*N - a*N*P$ (proies : croissance - prédation), $dP/dt = b*a*N*P - m*P$ (prédateurs : gains - mortalité). r = taux de reproduction des proies, a = taux de prédation par prédateur, b = efficacité de conversion proie $\rightarrow$ prédateur (0-1), m = taux de mortalité naturelle des prédateurs. Intégration numérique par `scipy.integrate.odeint` (RK4 adaptatif).

```
dN/dt = r*N - a*N*P [proies : croissance - prédation]
dP/dt = b*a*N*P - m*P [prédateurs : gains - mortalité]
Point d'équilibre :  $N^* = m/(a*b)$ ,  $P^* = r/a$ 
Période des oscillations  $\approx 2*\pi / \sqrt{r*m}$  [approximation linéarisée]
```

Algorithme pas à pas

- Définition du système d'ODE (`lotka_volterra_ode`)
- Intégration numérique via `scipy.integrate.odeint` sur T années
- Tracé des courbes $N(t)$ et $P(t)$ superposées
- Tracé du portrait de phase P vs N (cycle limite)
- Marquage du point d'équilibre (N^* , P^*)

Application ornithologique

Illustre les cycles lemming-harfang des neiges, campagnol-busard, sauterelle-guifette, criquet-outarde. Fondement conceptuel pour comprendre les fluctuations annuelles des populations de rapaces liées aux cycles de rongeurs et les décisions de conservation qui en découlent (fermeture de la chasse aux années de faible densité de proies).

Paramètres d'entrée	Sorties et résultats
• Population initiale des proies N_0 • Population initiale des prédateurs P_0 • Paramètres r (reproduction proies), a (prédation), b (conversion), m (mort prédateurs) • Durée de simulation T (années)	• Courbes $N(t)$ et $P(t)$ superposées avec axes secondaires • Portrait de phase P vs N (cycle limite elliptique) • Point d'équilibre théorique (N^*, P^*) • Période approximative des oscillations

Comment interpréter les résultats

■ Le cycle proie-prédateur est décalé : le pic des prédateurs suit le pic des proies. Point d'équilibre : $N^* = m/(a \cdot b)$, $P^* = r/a$. Si r grand : proies abondantes → prédateurs nombreux → effondrement proies → chute prédateurs → reprise des proies. Le portrait de phase fermé (cycle limite) indique la neutralité du modèle de base — une perturbation ne ramène pas au même état.

Erreurs fréquentes à éviter

■ Interpréter le cycle comme stable : le modèle de Lotka-Volterra de base est neutralement stable (cycles de taille variable selon les conditions initiales). Les modèles réalistes (logistique pour les proies) ont des cycles amortis.

■ Ignorer les hypothèses simplificatrices : pas de structure d'âge, rencontres aléatoires, population fermée. Le modèle est conceptuel, non prédictif.

■ Choisir des paramètres conduisant à une extinction numérique : si $P_0 \gg P^*$, les prédateurs surexploient les proies et s'effondrent.

Importance en écologie et conservation

Le modèle de Lotka-Volterra est un pilier de l'écologie théorique. Il introduit les notions d'interaction spécifique, de dynamique couplée et de cycle limite — concepts applicables à la gestion des rapaces, à la prévision des explosions de proies et à la compréhension des cascades trophiques dans les écosystèmes.

Référence clé

Lotka, A.J. (1925). Elements of Physical Biology. Williams & Wilkins, Baltimore.

DYNAMIQUE
DES
POPULATIONS

6.8. Séries temporelles de population

Description

Analyse une série temporelle d'abondance annuelle pour détecter une tendance significative (croissance ou déclin). Applique le test non paramétrique de Mann-Kendall, une régression linéaire OLS (pente annuelle absolue), et un lissage par moyenne mobile. Calcule le taux de variation annuel et évalue la puissance statistique de la tendance détectée.

Fondements méthodologiques

Mann-Kendall : $S = \sum_{i < j} \text{sign}(y_j - y_i)$. $\text{Var}(S) = n(n-1)(2n+5)/18$ (sans ex aequo). Statistique $z = (S - \text{sign}(S)) / \sqrt{\text{Var}(S)}$. Hypothèse nulle : pas de tendance monotone. Régression OLS : pente = variation absolue annuelle (individus/an). Lissage : moyenne mobile sur une fenêtre de k années (ajustable 2-7 ans).

```
Mann-Kendall  $S = \sum_{i < j} \text{sign}(y_j - y_i)$   
 $\text{Var}(S) = n(n-1)(2n+5) / 18$  [sans ex aequo]  
 $z = (S - \text{sign}(S)) / \sqrt{\text{Var}(S)}$  [ $N(0,1)$  sous  $H_0$ ]
```

```
Pente OLS :  $b = \text{sum}((t_i - t_{\text{bar}}) * (y_i - y_{\text{bar}})) / \text{sum}((t_i - t_{\text{bar}})^2)$   
Taux annuel =  $(b / y_{\text{bar}}) * 100\%$  [variation relative par an]
```

Algorithme pas à pas

- Calcul du score S de Mann-Kendall (toutes les paires $i < j$)
- Calcul de la variance de S et de la statistique z
- Régression OLS (scipy.stats.linregress) pente et R^2
- Lissage par moyenne mobile (pandas.rolling().mean())
- Tracé courbe des effectifs + lissage + droite OLS
- Interprétation : tendance (hausse/baisse/stable), significativité, magnitude

Application ornithologique

Analyse des données STOC, BBS, Wetland Bird Survey, LPO. Détection des déclin ou reprises de populations (pinson des arbres, alouette des champs, hirondelle rustique, courlis cendré). Utilisé pour produire les Listes Rouges régionales et calibrer les alertes précoces de l'Observatoire National de la Biodiversité.

Paramètres d'entrée

- Série temporelle : colonne année et colonne effectif (ou index)
- Ou paramètres de simulation (N_0 , r moyen, bruit stochastique)
- Fenêtre de lissage k (2-7 ans)

Sorties et résultats

- Courbe des effectifs + tendance lissée + droite de régression OLS
- Test Mann-Kendall : S, z, p-value, sens de la tendance
- Pente OLS (individus/an) et R^2
- Taux de variation annuel relatif (%)

Comment interpréter les résultats

■ Mann-Kendall $p < 0.05$ avec $S < 0$: tendance à la baisse significative. $S > 0$: tendance à la hausse. $|z| > 1.96$: significatif à 5%. Pente OLS = -5 ind/an avec $N_{\text{moyen}} = 100$: déclin de 5%/an. R^2 faible mais Mann-Kendall significatif : tendance monotone mais non linéaire (commun dans les comptages avec variabilité inter-annuelle).

Erreurs fréquentes à éviter

■ Utiliser le test t sur la pente OLS sans vérifier l'autocorrélation temporelle : les comptages annuels sont souvent autocorrélés, gonflant la significativité. Mann-Kendall est plus robuste car non paramétrique.

■ Confondre tendance à court terme et tendance à long terme : une série de 5 ans peut montrer un déclin artificiel lié à une variabilité naturelle.

■ Appliquer Mann-Kendall à des séries avec une forte saisonnalité non corrigée : le test suppose une tendance monotone, pas des cycles.

Importance en écologie et conservation

La détection rigoureuse des tendances démographiques est la base des Listes Rouges UICN et des plans de conservation nationaux. Le test de Mann-Kendall est préféré car il ne suppose pas la normalité des résidus, fréquente dans les comptages d'oiseaux avec surdispersion.

Référence clé

Hirsch, R.M. et al. (1982). Techniques of trend analysis for monthly water quality data. *Water Resources Research* 18(1): 107-121.

6.9. PVA et conservation

Description

Analyse de Viabilité des Populations (PVA) : simule stochastiquement 1000 trajectoires possibles d'une population sur T années sous incertitude environnementale (variance du taux d'accroissement), avec capacité de charge K et seuil de quasi-extinction. Estime la probabilité d'extinction, la médiane et les IC 95% de la taille finale de population.

Fondements méthodologiques

Croissance log-normale stochastique : $N(t+1) = \min(N(t) * \exp(r_t), K)$, avec $r_t \sim N(\mu_r, \sigma_r^2)$ tiré aléatoirement à chaque pas de temps. Stochasticité environnementale : σ_r représente la variabilité inter-annuelle du taux d'accroissement (climat, proies, prédateurs). 1000 réplifications par défaut. Risque d'extinction = $P(\min_{t=1..T}\{N(t)\} < \text{seuil})$. IC 95% par percentiles (2.5% et 97.5%) des 1000 trajectoires finales.

```
N(t+1) = min( N(t) * exp(r_t), K ) [croissance log-normale bornée par K]
r_t ~ N(mu_r, sigma_r^2) [stochasticité environnementale]
P(extinction) = N_simulations avec min(N) < seuil / N_total
Médiane finale = percentile 50% de {N_final[i], i=1..1000}
IC 95% = [percentile 2.5%, percentile 97.5%] des N_finaux
```

Algorithme pas à pas

- Initialisation de 1000 trajectoires à N_0
- Pour chaque trajectoire i et chaque année t : tirer $r_t \sim N(\mu_r, \sigma_r)$, calculer $N(t+1) = \min(N(t)*\exp(r_t), K)$, appliquer perte annuelle
- Calcul du risque d'extinction pour chaque trajectoire
- Agrégation : médiane, IC 95%, risque d'extinction global
- Tracé de la bande d'enveloppe (IC 95%) + médiane
- Histogramme de distribution des effectifs finaux

Application ornithologique

Outil clé pour les plans de sauvegarde d'espèces menacées : vautour moine, percnoptère, grand tétras, bécasseau maubèche, grèbe à cou noir. Utilisé par le Comité Français de l'UICN pour classer les espèces et par les gestionnaires de réserves pour dimensionner les effectifs minimaux viables.

Paramètres d'entrée

Sorties et résultats

- Population initiale N_0
- Taux d'accroissement moyen μ_r et écart-type σ_r
- Capacité de charge K
- Seuil de quasi-extinction (ex. 10 individus)
- Durée T (années) et nombre de simulations (défaut 1000)
- Bande enveloppe des trajectoires stochastiques (IC 95% + médiane)
- Risque d'extinction (probabilité en %)
- Médiane et IC 95% de la taille finale de population
- Histogramme de distribution des effectifs finaux

Comment interpréter les résultats

■ Risque d'extinction > 10% sur 100 ans : critère UICN d'espèce menacée (CR). Médiane finale > $K/2$: population viable à long terme. Bande IC 95% très large : haute incertitude — σ_r élevé. Trajectoires qui s'effondrent avant T : quasi-extinctions prématurées. Comparer la médiane avec et sans mesure de conservation pour évaluer l'impact.

Erreurs fréquentes à éviter

- Ignorer la stochasticité démographique (en plus de la stochasticité environnementale) pour les très petites populations ($N < 50$) : les fluctuations dues au hasard des naissances/décès deviennent critiques.
- Utiliser une seule simulation plutôt que 1000 : la variabilité stochastique rend une trajectoire unique non représentative.
- Confondre μ_r et taux de croissance observé d'une seule période : calibrer μ_r sur des séries temporelles longues (> 10 ans) si possible.

Importance en écologie et conservation

La PVA est l'outil de référence international pour la gestion des espèces vulnérables. Elle intègre l'incertitude environnementale — inévitable en écologie — pour fournir des probabilités d'extinction utiles à la décision politique. Beissinger & McCullough (2002) synthétisent les meilleures pratiques pour la PVA en conservation.

Référence clé

Beissinger, S.R. & McCullough, D.R. (eds, 2002). Population Viability Analysis. University of Chicago Press.

**DYNAMIQUE
DES
POPULATIONS**

6.10. Scénarios de gestion

Description

Compare quatre scénarios d'action de conservation sur une population simulée : sans action, restauration d'habitat (K plus élevé, mortalité réduite), réduction de mortalité (chasse, pièges, collisions), et action combinée. Visualise les trajectoires médianes par scénario et produit un tableau

comparatif de la médiane finale, du risque d'extinction et du lambda apparent.

Fondements méthodologiques

Chaque scénario modifie les paramètres démographiques (μ_r , σ_r , K, perte annuelle) et lance une simulation PVA indépendante. Comparaison par : médiane de la population à T ans, risque d'extinction sur T ans, lambda apparent (taux de croissance moyen sur la période). L'action combinée maximise généralement tous les indicateurs. Permet de classer les actions par efficacité relative avant décision.

```
Lambda apparent :  $\lambda_{app} = \exp(\log(N_{median}(T) / N_0) / T)$   
Gain médian :  $(N_{scénario} - N_{sans\_action}) / N_{sans\_action} * 100\%$   
Risque relatif :  $P_{ext\_sans\_action} / P_{ext\_scénario}$  [combien de fois réduit]
```

Algorithme pas à pas

- Définition de 4 scénarios avec leurs paramètres spécifiques
- Lancement de la simulation PVA (1000 répliques) pour chaque scénario
- Extraction des médianes, IC 95% et risques d'extinction par scénario
- Construction du tableau comparatif
- Tracé des courbes médianes $N(t)$ par scénario (couleurs distinctes)
- Identification du meilleur scénario (minimum risque d'extinction ou maximum médiane)

Application ornithologique

Directement applicable aux Plans Nationaux d'Action (PNA) pour des espèces comme le gypaète barbu, le vautour percnoptère, le grand tétras, l'outarde canepetière. Compare les coûts-bénéfices de différents types d'intervention avant la décision politique et le budget alloué par les services de l'État.

Paramètres d'entrée	Sorties et résultats
• Paramètres de la population de référence (μ_r, σ_r, K, N_0, seuil) • 4 scénarios préconfigurés avec variation des paramètres clés • Durée de projection T (années)	• Courbes médianes $N(t)$ par scénario sur un graphique commun • Tableau comparatif : médiane finale, risque extinction %, lambda apparent • Meilleur scénario identifié automatiquement • Gain en médiane finale par rapport au scénario sans action (%)

Comment interpréter les résultats

■ Un scénario avec risque d'extinction < 5% sur 100 ans est considéré comme viable selon les critères UICN. La différence entre 'Réduction mortalité' et 'Restauration habitat' dépend des paramètres biologiques de l'espèce : pour les espèces à forte longévité, réduire la mortalité adulte est généralement plus efficace. L'action combinée montre souvent des effets synergiques (gains > somme des effets séparés).

Erreurs fréquentes à éviter

■ Supposer des effets additifs indépendants entre actions : restaurer l'habitat ET réduire la mortalité peut avoir des effets synergiques non capturés si les paramètres sont traités indépendamment.

■ Ignorer l'incertitude sur les paramètres (μ_r , K) : présenter une seule projection déterministe sans intervalle de confiance sur les scénarios crée une fausse impression de précision.

■ Comparer des scénarios avec des budgets très différents sans analyse coût-efficacité : l'action combinée est souvent la meilleure mais aussi la plus coûteuse.

Importance en écologie et conservation

La comparaison systématique de scénarios est fondamentale pour la décision en conservation. Elle évite d'investir des ressources limitées dans des actions à faible impact démographique, et oriente vers les leviers les plus efficaces. Les PNA français utilisent désormais ce type d'analyse.

Référence clé

Morris, W.F. & Doak, D.F. (2002). Quantitative Conservation Biology. Sinauer Associates, Sunderland, MA.

Section 7 — Annexes techniques

7.1 Dépendances Python et versions recommandées

ORNI-LAB repose sur les bibliothèques scientifiques Python suivantes. Les versions indiquées sont celles testées et validées. Des versions antérieures peuvent fonctionner mais certaines corrections (notamment statsmodels ≥ 0.14 pour le modèle mixte) sont critiques.

Bibliothèque	Version min.	Rôle principal
streamlit	1.40	Framework web interactif, gestion de session, widgets
numpy	1.24	Calculs matriciels, algèbre linéaire (Leslie, KDE, PVA)
pandas	2.0	Manipulation de DataFrames, import CSV, statistiques
scipy	1.11	Tests statistiques, optimisation, intégration ODE, KDE
statsmodels	0.14	GLM, modèles mixtes LMM (bse_fe critique ≥ 0.14)
plotly	5.18	Graphiques interactifs (scatter, bar, heatmap, contour)
reportlab	4.0	Génération des rapports PDF (export module)
matplotlib	3.7	Figures de diagnostics (Q-Q plots, résidus)

7.2 Sécurité et robustesse de l'application

ORNI-LAB a été audité pour les vecteurs d'attaque courants des applications web Streamlit. Voici les mesures de sécurité en place :

- **Aucun eval() / exec()** — le code n'évalue jamais de chaînes de caractères utilisateur comme du code Python (pas de RCE possible).
- **Lecture seule des CSV** — les fichiers uploadés sont lus en mémoire via pandas, jamais écrits sur le disque ni exécutés.
- **Pas de base de données** — pas de risque d'injection SQL.
- **Pas d'authentification** — l'application est locale (localhost:8501), non exposée sur Internet.
- **try/except global** — depuis v2.0, chaque renderer est encapsulé dans un try/except : une erreur dans un module n'expose pas de traceback brut à l'utilisateur final et ne plante pas l'application.
- **Nettoyage des données** — les valeurs nulles et types incorrects sont normalisés avant tout calcul (pas d'injection via les données).

7.3 Problèmes fréquents et solutions

Problème : L'application ne démarre pas — ModuleNotFoundError

- Vérifier que toutes les dépendances sont installées : `pip install streamlit numpy scipy pandas statsmodels plotly reportlab`. Utiliser un environnement virtuel dédié pour éviter les conflits de versions.

Problème : Port 8501 déjà utilisé

- Le fichier ORNI-LAB.bat libère automatiquement le port avant de lancer Streamlit. En ligne de commande : `netstat -ano | findstr :8501` pour trouver le PID, puis `taskkill /F /PID`.

Problème : Erreur dans le modèle mixte : Length mismatch

- Causé par statsmodels < 0.14 où `result.bse` incluait 3 éléments au lieu de 2. La version 2.0 extrait les éléments par indice numpy `[:n_fe]` — correctif appliqué.

Problème : Encodage incorrect dans le CSV (caractères corrompus)

- Utiliser l'encodage UTF-8 BOM lors de l'export Excel. Le module Analyse CSV essaie automatiquement 5 encodages. En dernier recours, ouvrir le fichier dans Notepad++ et reconvertir en UTF-8.

Problème : Erreur linregress : Cannot calculate regression (std = 0)

- Une colonne constante (tous les individus ont la même valeur) ne permet pas de calculer une régression. Le module `regression.py` v2.0 affiche un avertissement clair et retourne sans planter.

Problème : Les graphiques ne s'affichent pas dans le navigateur

- Vider le cache du navigateur (Ctrl+F5). Si l'erreur persiste, vérifier que `use_container_width=True` est bien passé à `st.plotly_chart`. Sous Firefox, désactiver les extensions de blocage de scripts.

Section 8 — Glossaire des termes statistiques

8. Glossaire des termes statistiques et écologiques

AIC (Akaike Information Criterion)

Critère de sélection de modèle : $AIC = -2 \cdot \log(L) + 2 \cdot k$. Plus l'AIC est bas, meilleur est le compromis ajustement/parcimonie. Différence $\Delta AIC > 2$ indique un support substantiel pour le modèle à AIC plus bas.

Bandwidth (KDE)

Paramètre de lissage de l'estimateur à noyau (KDE). Un bandwidth trop petit produit un sur-ajustement (nombreux pics), trop grand un sous-ajustement (zones trop étalées). La règle de Scott donne un bandwidth automatique optimal pour les distributions gaussiennes.

Capacité de charge (K)

Taille de population maximale que peut supporter un environnement donné. Dans le modèle logistique, la population converge vers K. Dépend des ressources disponibles (habitat, nourriture, sites de nidification).

CMR (Capture-Marquage-Recapture)

Famille de méthodes pour estimer l'abondance et la survie à partir de données de capture répétées. Lincoln-Petersen (2 sessions) est le modèle de base ; Cormack-Jolly-Seber (CJS) estime la survie apparente avec sessions multiples.

Cohen d

Taille d'effet standardisée pour la comparaison de deux moyennes : $d = (x1_bar - x2_bar) / s_pooled$. Conventions : 0.2 = faible, 0.5 = modéré, 0.8 = fort. Indépendant de la taille d'échantillon.

Détectabilité (p)

Probabilité qu'un individu présent sur un site soit détecté lors d'une visite. Si $p < 1$, l'absence apparente ne prouve pas l'absence réelle. La correction pour p est le fondement des modèles d'occupation et du distance sampling.

Distribution stable (Leslie)

Répartition asymptotique de la population entre classes d'âge, atteinte indépendamment de la distribution initiale. Correspond au vecteur propre droit de la matrice de Leslie.

Élasticité

Sensibilité relative d'une valeur propre (λ) aux changements proportionnels d'un paramètre de la matrice de Leslie. Somme à 1 sur tous les éléments. Identifie les paramètres démographiques les plus importants pour la croissance.

ESW (Effective Strip Width)

Largeur de bande hypothétique dans laquelle tous les individus seraient détectés avec certitude et qui donnerait le même nombre de détections que la bande réelle. $ESW = \int_0^W g(x) dx$.

GLM (Generalized Linear Model)

Extension de la régression linéaire pour des distributions non gaussiennes de Y. Le GLM Poisson est adapté aux comptages, le logistique aux présences/absences. Le lien canonique (log pour Poisson, logit pour binomial) relie le prédicteur linéaire à l'espérance de Y.

ICC (Intraclass Correlation Coefficient)

Proportion de la variance totale d'une variable due aux différences entre groupes : $ICC = \sigma^2_b / (\sigma^2_b + \sigma^2_e)$. $ICC > 0.1$ justifie l'usage d'un modèle mixte. $ICC = 0$: toute la variance est intra-groupe.

IRR (Incidence Rate Ratio)

Ratio des taux d'incidence dans un GLM Poisson ou BN : $IRR = \exp(\beta)$. $IRR = 1.5$ pour l'habitat forêt signifie : l'abondance est 1.5x plus élevée en forêt qu'en habitat de référence.

Lambda (matrice de Leslie)

Valeur propre dominante de la matrice de Leslie. $\lambda > 1$: croissance, $\lambda = 1$: stabilité, $\lambda < 1$: déclin. Relation avec r : $\lambda = \exp(r)$.

Mann-Kendall (test de)

Test non paramétrique de détection d'une tendance monotone dans une série temporelle. Robuste aux non-normalités et aux valeurs aberrantes. H_0 : pas de tendance. Statistique S = somme des signes des différences.

MCP (Minimum Convex Polygon)

Plus petit polygone convexe contenant $X\%$ des localisations d'un individu. Méthode historique (Mohr 1947) pour estimer le domaine vital. Simple mais sensible aux localisations extrêmes.

OLS (Ordinary Least Squares)

Méthode d'estimation de la régression linéaire minimisant la somme des carrés des résidus. Estimateur BLUE (Best Linear Unbiased Estimator) si les hypothèses de Gauss-Markov sont vérifiées.

p-value

Probabilité d'observer un résultat au moins aussi extrême que celui observé si H_0 est vraie. $p < 0.05$: résultat significatif au seuil 5%. La p-value ne mesure pas l'importance biologique — toujours l'accompagner d'une taille d'effet.

PVA (Population Viability Analysis)

Ensemble de méthodes stochastiques pour estimer le risque d'extinction d'une population à un horizon temporel donné. Intègre l'incertitude environnementale et démographique. Fondement des Plans Nationaux d'Action (PNA).

R² (coefficient de détermination)

Proportion de la variance de Y expliquée par le modèle : $R^2 = 1 - SSE/SST$. $R^2 = 1$: ajustement parfait. $R^2 = 0$: le modèle n'explique rien. Sensible aux valeurs aberrantes et non adapté aux GLM.

REML (Restricted Maximum Likelihood)

Méthode d'estimation des composantes de variance dans les modèles mixtes. Corrige le biais de sous-estimation de σ^2_b du ML classique. Recommandé pour estimer les effets aléatoires ; utiliser ML uniquement pour comparer des modèles avec effets fixes différents.

Shannon (indice de)

Indice de diversité : $H' = -\sum(p_i * \ln(p_i))$. $H' = 0$: une seule espèce. $H' = \ln(S)$: toutes les espèces également abondantes. Sensible à la richesse spécifique et à l'équitabilité.

Surdispersion

Variance observée supérieure à la variance théorique d'un modèle. Dans un GLM Poisson : $\phi = \chi^2_{\text{Pearson}} / df > 1$. Cause habituelle : agrégation spatiale, hétérogénéité non modélisée, excès de zéros. Solution : GLM Binomial Négatif ou quasi-Poisson.

Section 9 — Références bibliographiques

9. Références bibliographiques

- Buckland, S.T., Anderson, D.R., Burnham, K.P., Laake, J.L., Borchers, D.L. & Thomas, L. (2001). Introduction to Distance Sampling: Estimating Abundance of Biological Populations. Oxford University Press, Oxford.
- Caswell, H. (2001). Matrix Population Models: Construction, Analysis, and Interpretation, 2nd ed. Sinauer Associates, Sunderland, MA.
- Beissinger, S.R. & McCullough, D.R. (eds, 2002). Population Viability Analysis. University of Chicago Press, Chicago.
- MacKenzie, D.I., Nichols, J.D., Lachman, G.B., Droege, S., Royle, J.A. & Langtimm, C.A. (2002). Estimating site occupancy rates when detection probabilities are less than one. *Ecology* 83(8): 2248-2255.
- Mohr, C.O. (1947). Table of equivalent populations of North American small mammals. *American Midland Naturalist* 37(1): 223-249.
- Lincoln, F.C. (1930). Calculating Waterfowl Abundance on the Basis of Banding Returns. U.S. Department of Agriculture Circular 118: 1-4.
- Verhulst, P.F. (1838). Notice sur la loi que la population suit dans son accroissement. *Correspondance Mathématique et Physique* 10: 113-121.
- Silverman, B.W. (1986). Density Estimation for Statistics and Data Analysis. Chapman and Hall, London.
- Shannon, C.E. & Weaver, W. (1949). The Mathematical Theory of Communication. University of Illinois Press, Urbana.
- Lotka, A.J. (1925). Elements of Physical Biology. Williams & Wilkins, Baltimore.
- Volterra, V. (1926). Fluctuations in the Abundance of a Species Considered Mathematically. *Nature* 118: 558-560.
- Zuur, A.F., Ieno, E.N., Walker, N.J., Saveliev, A.A. & Smith, G.M. (2009). Mixed Effects Models and Extensions in Ecology with R. Springer, New York.
- McCullagh, P. & Nelder, J.A. (1989). Generalized Linear Models, 2nd ed. Chapman & Hall, London.
- Sokal, R.R. & Rohlf, F.J. (2012). Biometry: The Principles and Practice of Statistics in Biological Research, 4th ed. W.H. Freeman, New York.
- Zar, J.H. (2010). Biostatistical Analysis, 5th ed. Prentice Hall, Upper Saddle River, NJ.
- Morris, W.F. & Doak, D.F. (2002). Quantitative Conservation Biology: Theory and Practice of Population Viability Analysis. Sinauer Associates, Sunderland, MA.
- Hirsch, R.M., Slack, J.R. & Smith, R.A. (1982). Techniques of trend analysis for monthly water quality data. *Water Resources Research* 18(1): 107-121.
- Wickham, H. & Grolemund, G. (2017). R for Data Science. O'Reilly Media, Sebastopol, CA.
- Tukey, J.W. (1977). Exploratory Data Analysis. Addison-Wesley, Reading, MA.

ORNI-LAB v2.0 — Développé par **Abdoulaye Diop** · Bioinformaticien · Biomathématicien
Laboratoire Interactif de Modélisation Ornithologique · Mai 2026
dioplayes@gmail.com · +221 77 113 07 48